Sistemi Operativi

C.d.L. in Informatica (laurea triennale)
Anno Accademico 2022-2023

Canale A-L

Dipartimento di Matematica e Informatica – Catania

File System e Dischi

Prof. Mario Di Raimondo

I file system

- Problema di base: gestire **grandi quantità** di informazioni, in modo **persistente** e condiviso **tra più processi**;
- astrazione: **file** e **directory**;
- i dettagli di gestione ed implementazione costituiscono il **file system**;
- esempi di **dettagli**:
  - nomenclatura;
  - tipi di file;
  - tipi di accesso;
  - metadati (o attributi);
  - operazioni supportate sui file;
    - accesso condiviso ai file: i **lock**:
      - shared *vs.* exclusive;
      - mandatory *vs.* advisory;
- **strutture dati** per la gestione dei file: globale e per processo.

Struttura di un file system

- **Master Boot Record** (MBR);
- partizioni e **boot record** (o boot block);
- **superblocco**;

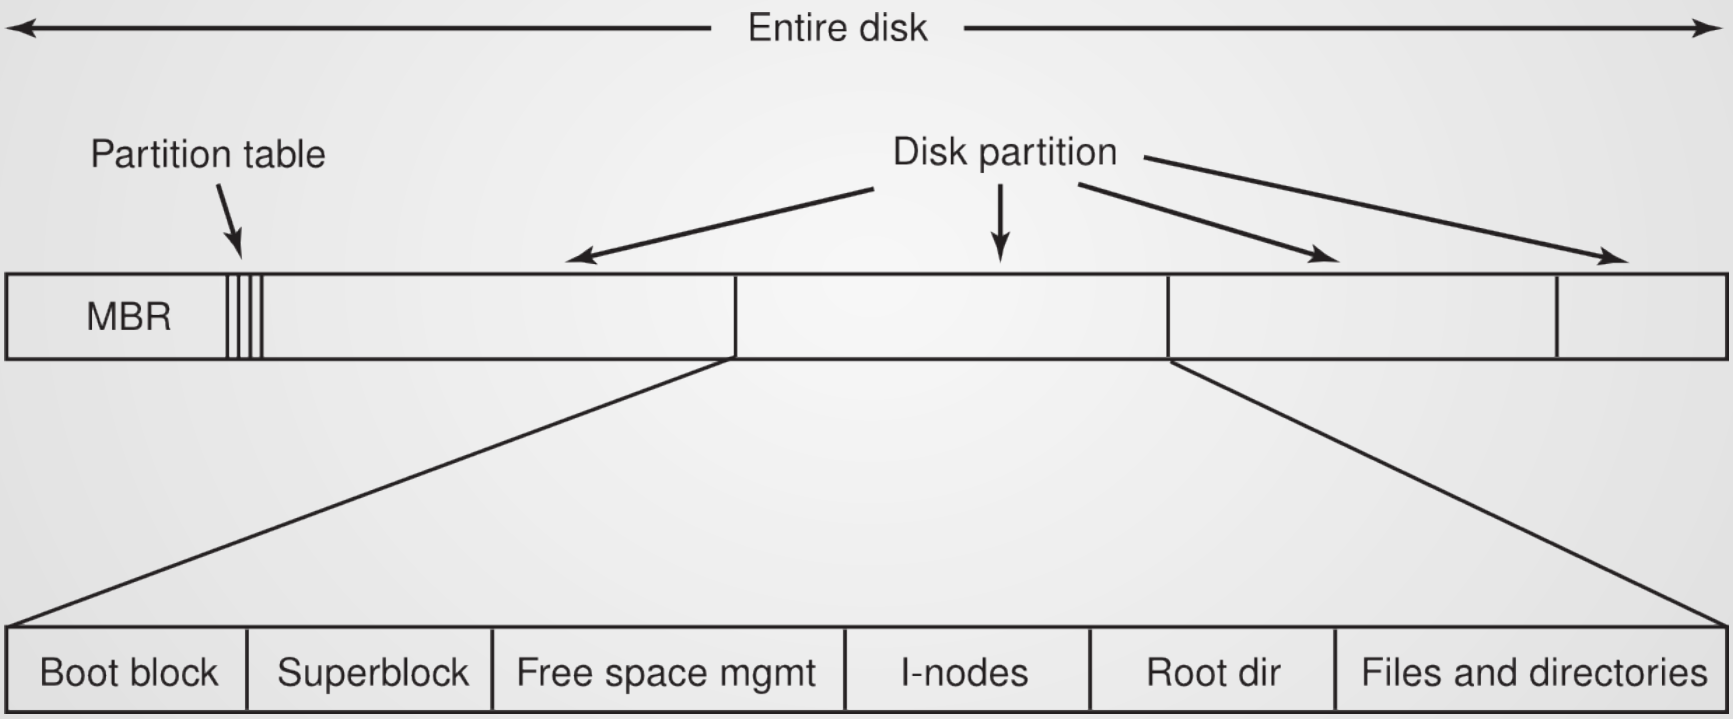

- layout moderno alternativo: **GPT** (GUID Partition Table) definito dallo standard **EFI**.

Implementazione dei file

- **Allocazione contigua.**

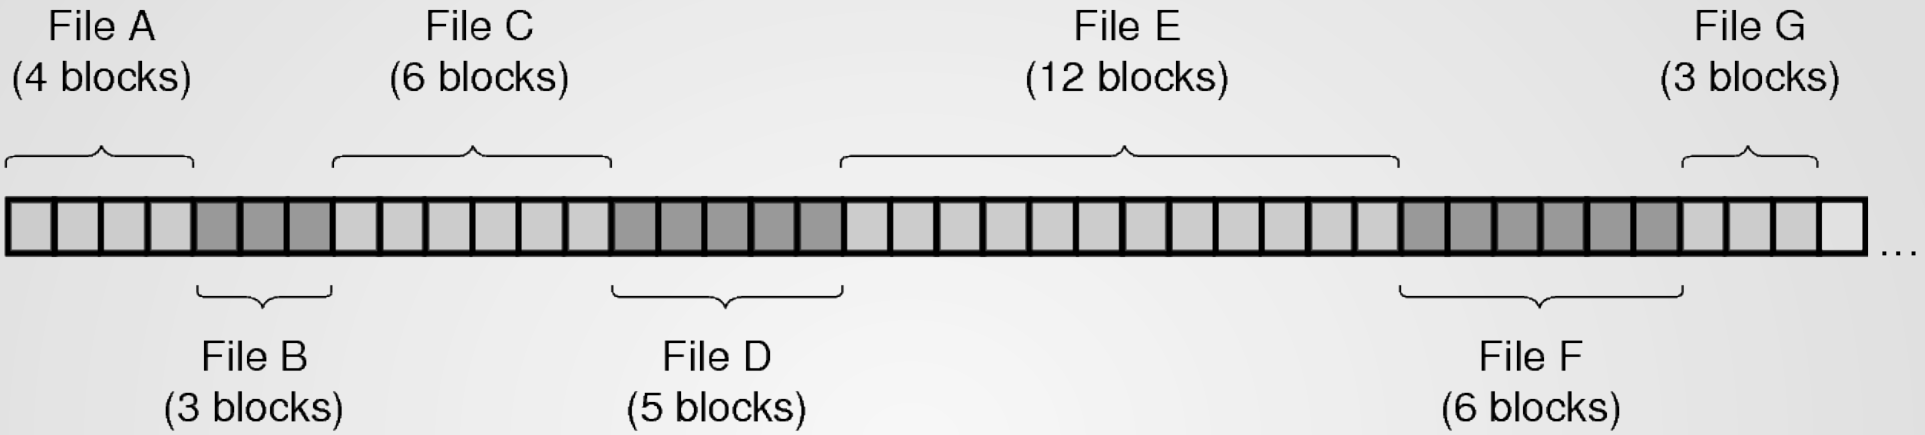

- **Allocazione con liste collegate** (o allocazione concatenata).

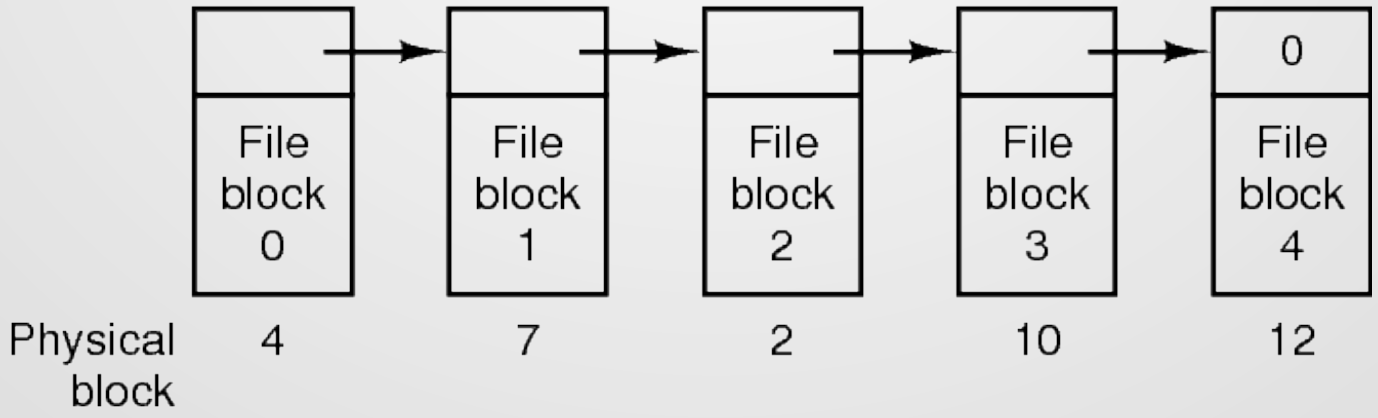

Implementazione dei file

- **Allocazione con liste collegate su una tabella di allocazione dei file** (file allocation table – **FAT**) (o allocazione tabellare).
- **Allocazione con nodi indice** (index node – **i-node**) (o allocazione indicizzata):
  - varianti: **collegata**, **multilivello, ibrida**.

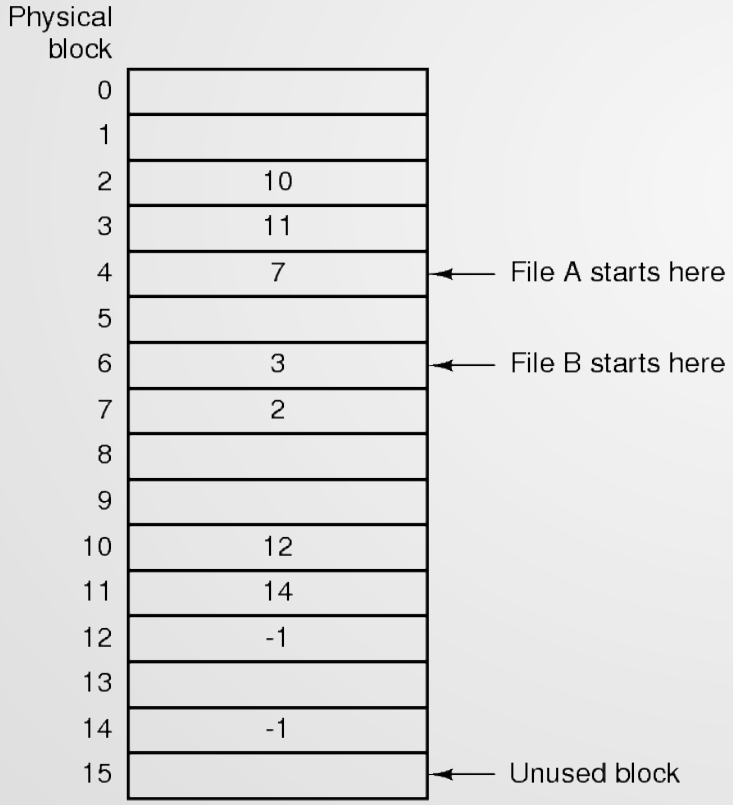

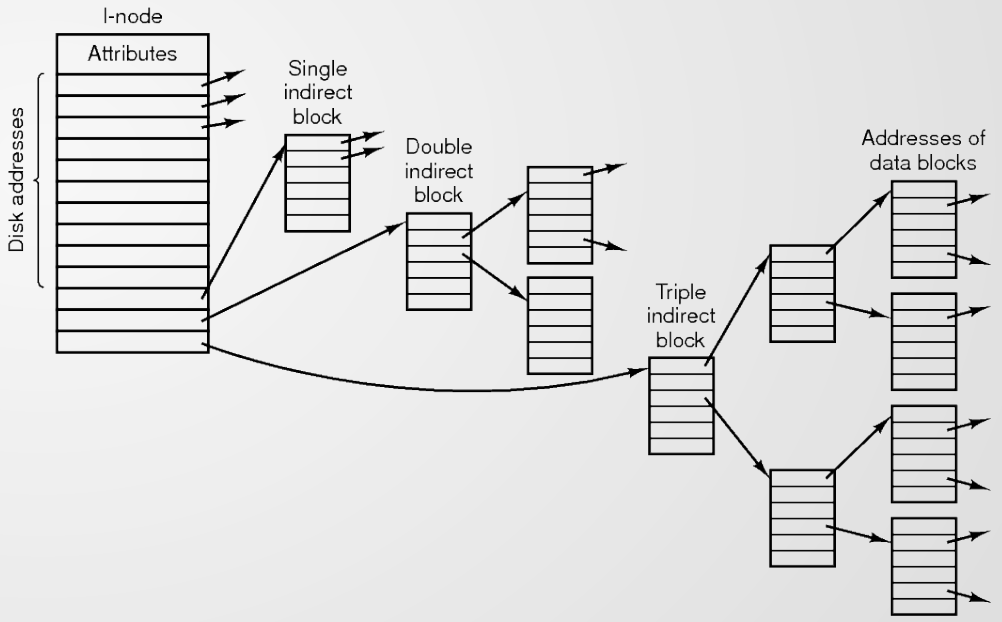

Implementazione delle directory

- Dove memorizzare i **metadati/attributi**?

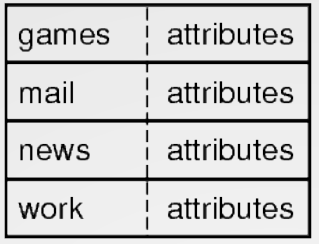

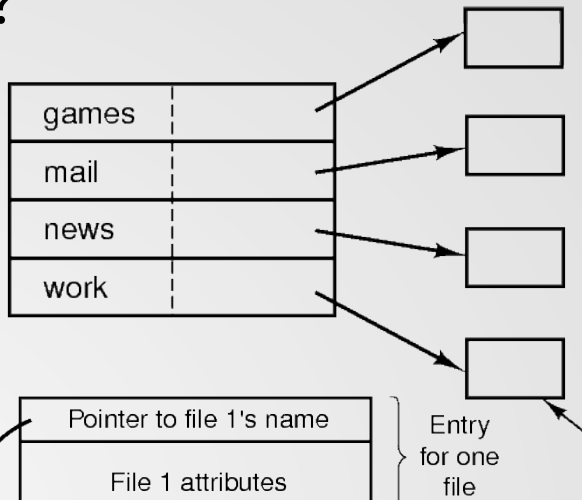

- **nomi lunghi:**
  - lung. variabile;
  - tramite heap;
- **prestazioni**:
  - tabella hash;
  - cache.

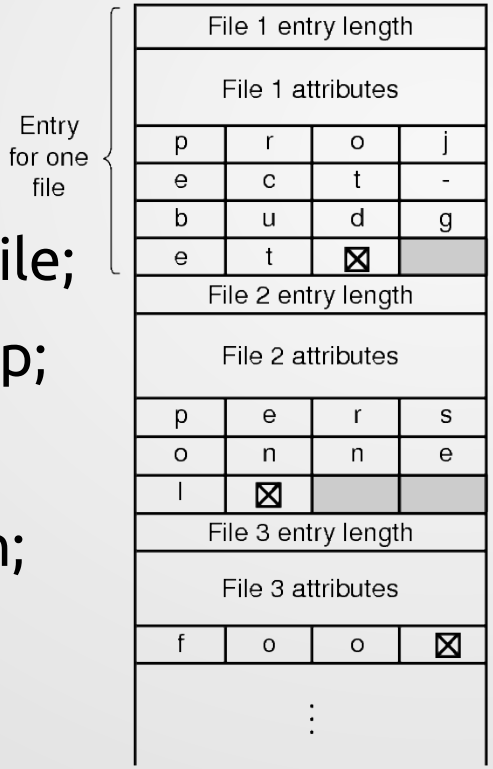

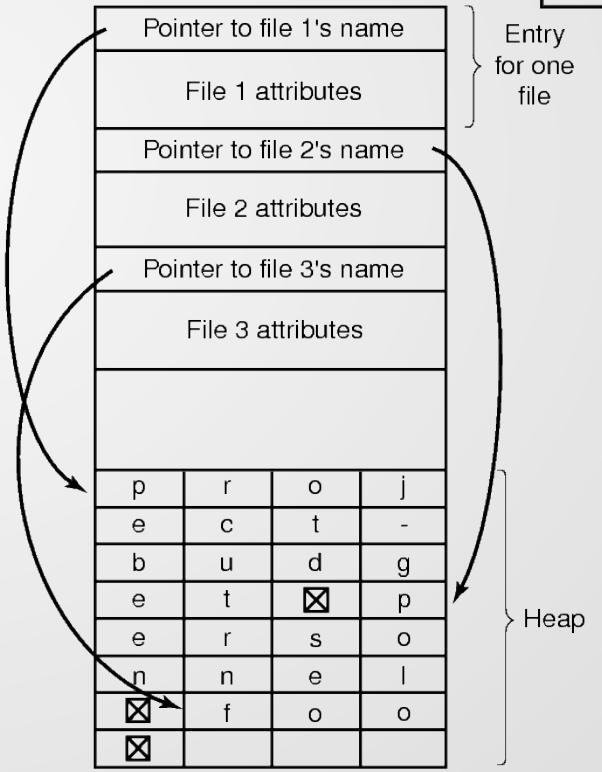

Condivisione di file su un file system

- **Scenario**: due o più utenti vogliono condividere un file;
- usando una FAT: duplicare la lista con i riferimenti ai blocchi;
  - problemi in caso di append;
- usando i-node: **hard-link**;
  - contatore dei link;
  - anomalia con accounting;

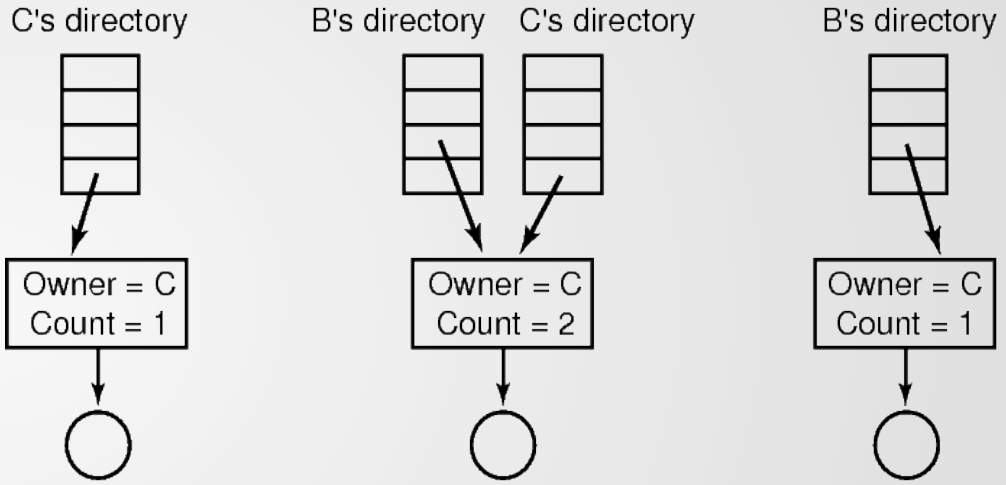

- ulteriore approccio: **soft-link**;
  - universale e permettere di fare riferimenti al di fuori del file system;
  - appesantimento nella gestione;
- eventuali **problemi** in fase di attraversamenti e backup.

Gestione blocchi liberi

- Attraverso l'uso di una **bitmap**:
  - relativamente **piccola**;
  - strategie di **allocazione in memoria**:
    - tutta in memoria, o;
    - un blocco alla volta;
      - paginata con VM;

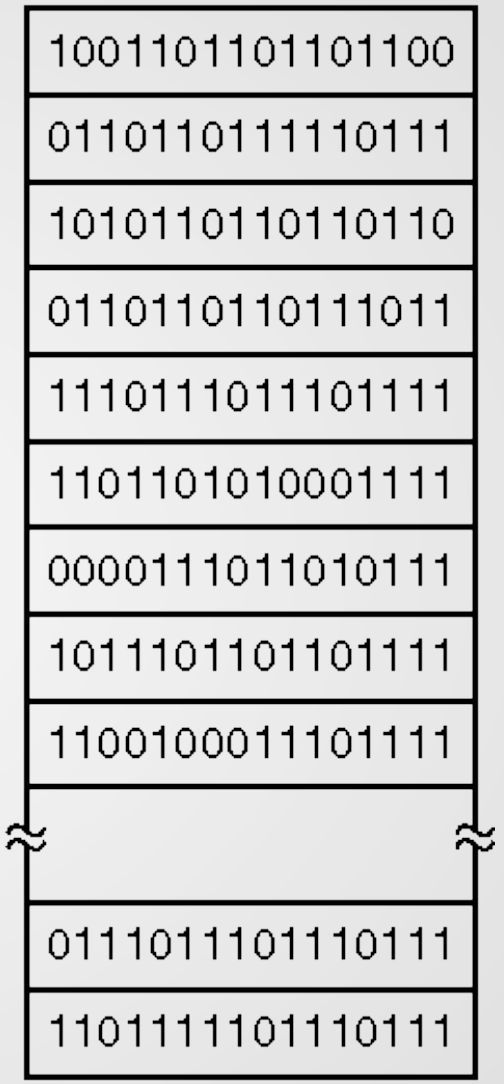

Gestione blocchi liberi

- attraverso l'uso di **liste concatenate**:
  - richiede più spazio;
    - ma si sfruttano i blocchi stessi liberi;
  - possibilità di inserire **contatori** per blocchi contigui.

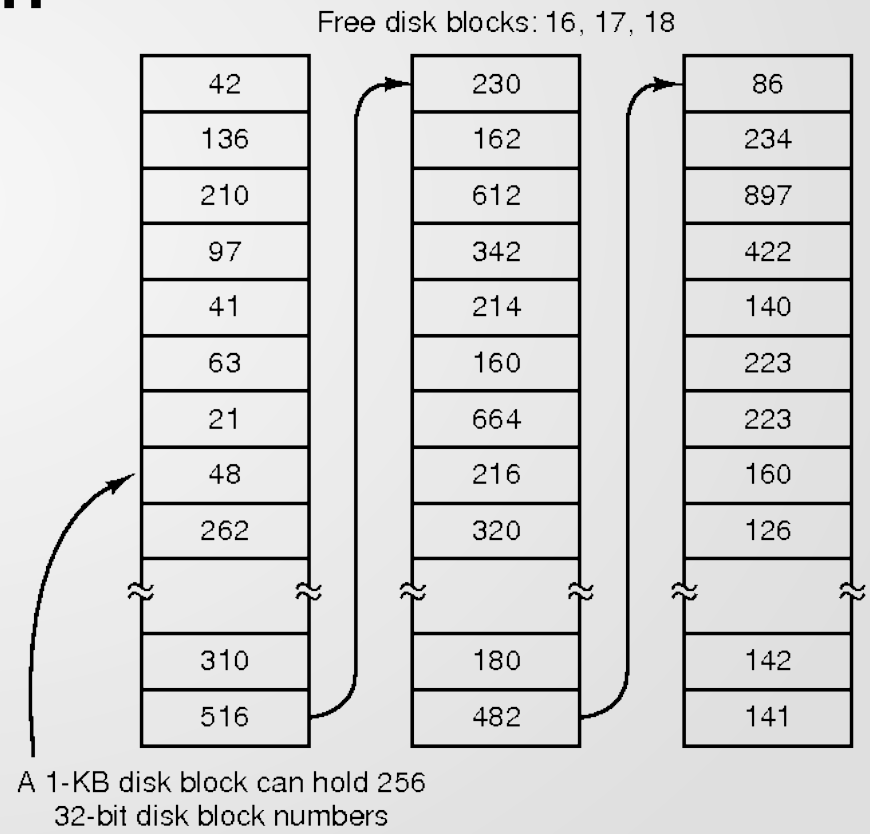

Controlli di consistenza

- A seguito di **crash** del sistema i file-system possono diventare inconsistenti;
- apposite **utility** possono effettuare dei **controlli di consistenza**:
  - sui **blocchi**;

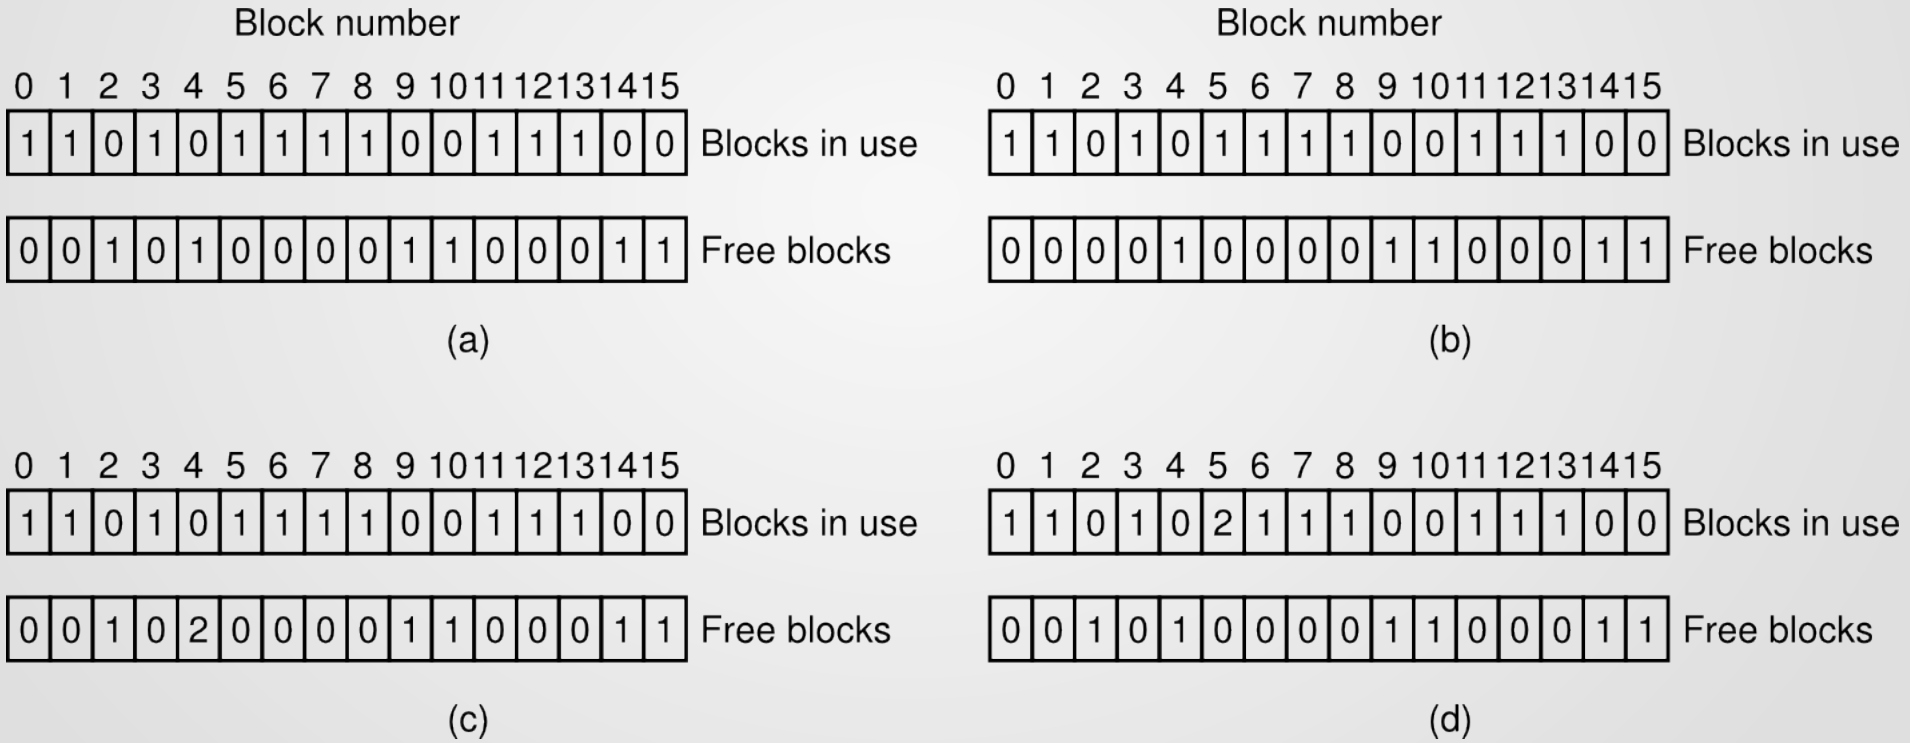

  - sui **riferimenti agli i-node**.

Journaling

- **strategia**:
  - le operazioni sui meta-dati sono preliminarmente appuntate in un log che viene poi ripulito a posteriori (subito dopo);
  - in caso di ripristino da crash: ripetere le operazioni in log;
- **benefici:**
  - maggiore robustezza dei metadati;
  - veloce ripristino da crash/reboot;
- affinché tutto funzioni bisogna operare con operazioni **idempotenti**.

Cache del disco

- Per migliorare le prestazioni dei dischi si fa spesso uso di una **cache del disco** (o **buffer cache**):
  - struttura basata su **tabelle hash**;

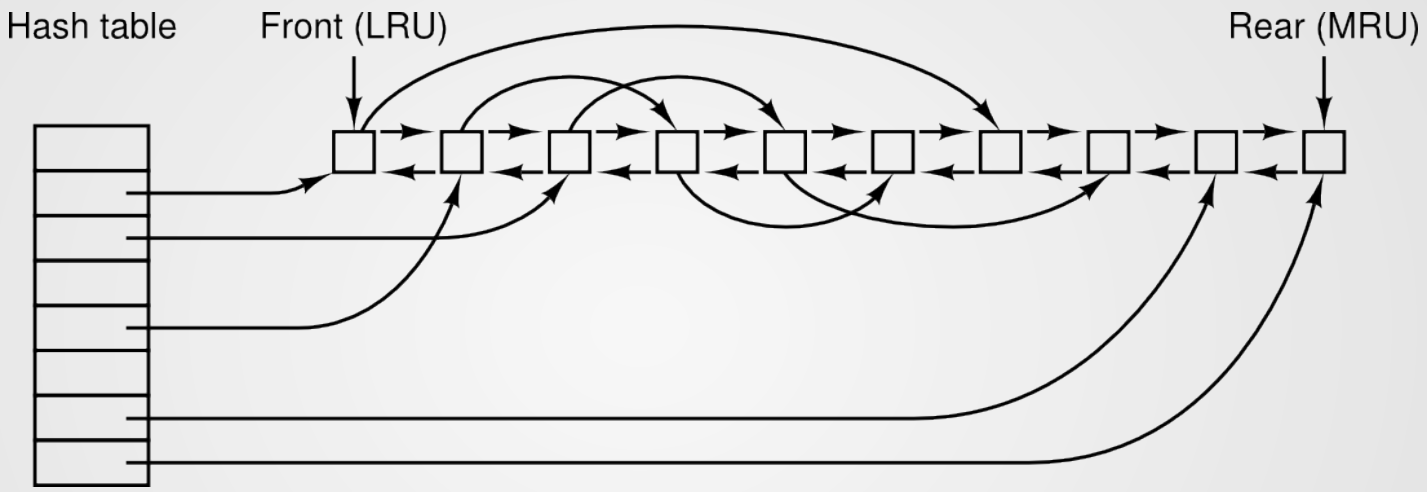

  - strategie di gestione:
    - **LRU modificata**;
    - **free-behind** & **read-ahead**;
- scrittura: **sincrona** *vs.* **asincrona**.

Cosa usano i nostri Sistemi Operativi?

- **Windows**:
  - exFAT su unità removibili;
  - NTFS su dischi fissi:
    - file-system moderno, molto complesso;
    - journaling, cifratura, compressione, copia shadow (CoW), dischi multipli (RAID) …
- **Linux**:
  - **ext-4**:
    - journaling, allocazione efficiente;
  - **BTRFS**:
    - recente file-system evoluto
    - journaling, check-sum dati e metadati, compressione, volumi, clonazione (CoW), dischi multipli (RAID), …
- **MacOS**: HFS+ recentemente soppiantato da APFS.

Scheduling del disco

- **Obiettivi**:
  - massimizzare il numero di richieste soddisfatte in una unità di tempo (**throughput**);
  - minizzare il **tempo medio di accesso**;

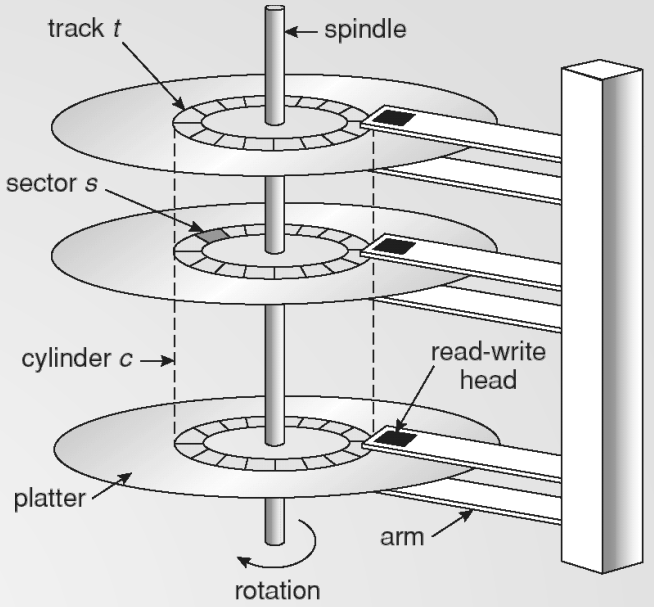

- in un sistema, soprattutto se multiprogrammato, si vengono a creare varie richieste di I/O su disco che però, tipicamente, possono essere inviate al controller del disco solo una alla volta. Si crea quindi una **coda** di **richieste pendenti**;
- Il S.O. può adottare varie **politiche di selezione** della prossima richiesta da mandare;
- si può ottimizzare per:
  - **tempo di posizionamento** (seek-time);
  - **latenza di rotazione**.

Ottimizzare il seek-time

- Vedremo varie politiche di scheduling su uno specifico **esempio**:
  - lista delle richieste in ordine di arrivo e per # di cilindro:
    98, 183, 37, 122, 14, 124, 65, 67
  - posizione iniziale della testina: cilindro ***53***
- **First Come First Served** (**FCFS**):
  - distanza totale percorsa: 640 tracce;
  - **semplice** da realizzare;
  - **equo**;
  - **inefficiente**;

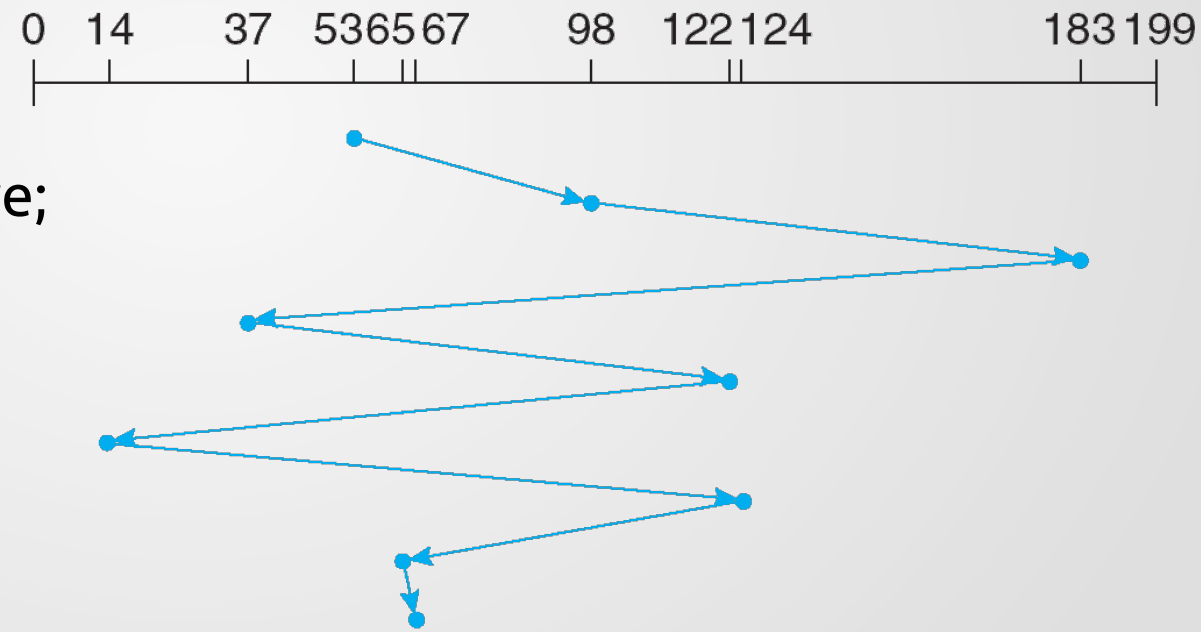

Ottimizzare il seek-time

- **esempio**: coda ***98, 183, 37, 122, 14, 124, 65, 67***; cilindro iniziale ***53***;
- **Shortest Seek Time First** (**SSTF**):
  - ordine usato: 65, 67, 37, 14, 98, 122, 124, 183;
  - distanza totale percorsa: 236 tracce;
  - **buone prestazioni**;
  - **non equo** (*starvation*);

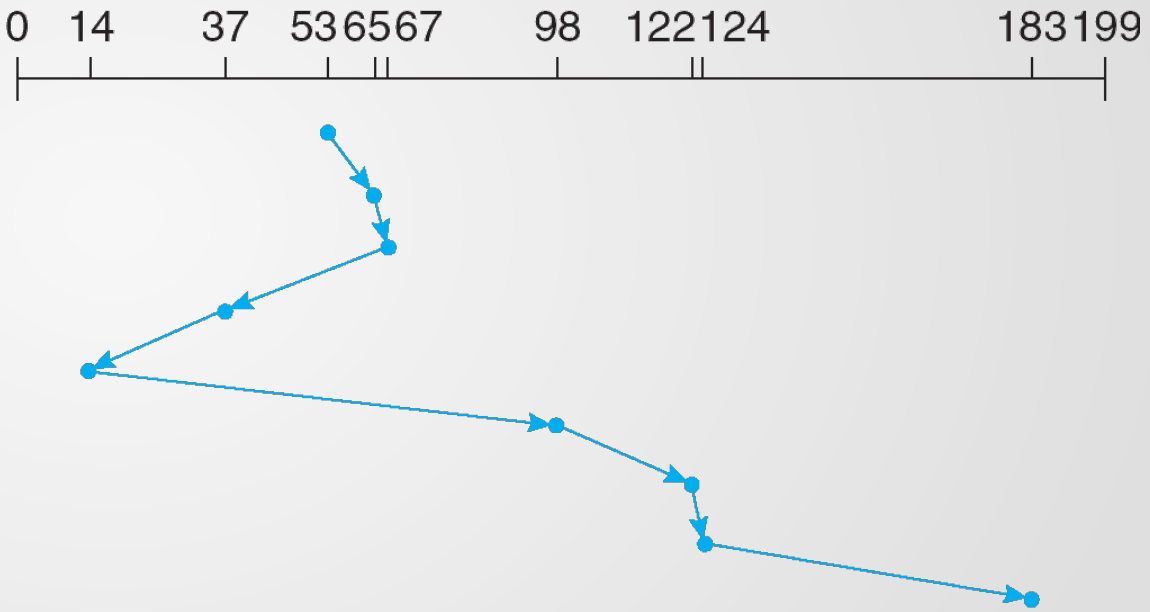

Ottimizzare il seek-time

- **esempio**: coda ***98, 183, 37, 122, 14, 124, 65, 67***; cilindro iniziale ***53***;
- **Scheduling per scansione** (algoritmo dell'ascensore):
  - mantiene un verso fino all'ultima richiesta in tale direzione
  - ordine usato (inizio UP): 65, 67, 98, 122, 124, 183, 37, 14
  - distanza totale: 299 tracce (più di SSTF)
  - scansione uniforme;
  - **garantisce** comunque una **attesa massima** per ogni richiesta

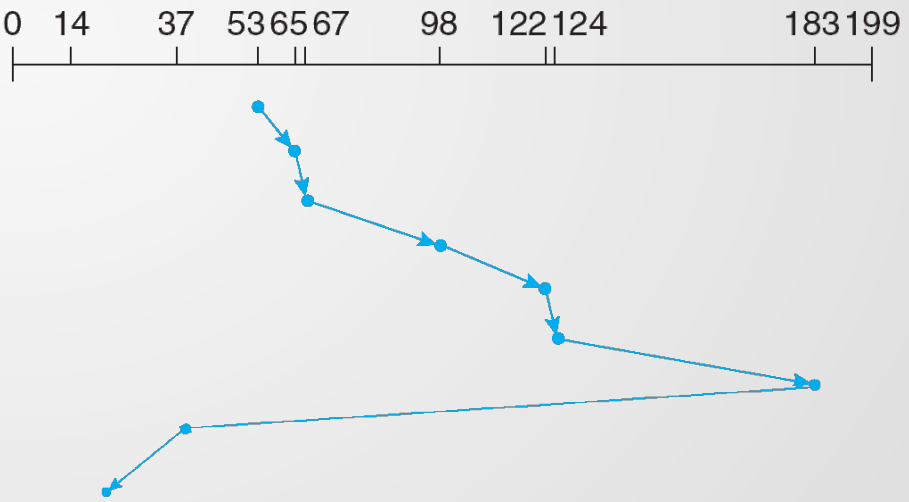

Ottimizzare il seek-time

- **esempio**: coda ***98, 183, 37, 122, 14, 124, 65, 67***; cilindro iniziale ***53***;
- **Scheduling per scansione circolare**:
  - considera le posizioni come collegate in **modo circolare**: arrivato alla fine del disco torna sul primo cilindro senza servire alcuna richiesta;
  - ordine usato: 65, 67, 98, 122, 124, 183, 14, 37
  - garantisce un **tempo medio di attesa** più **basso** in presenza di tante richieste.

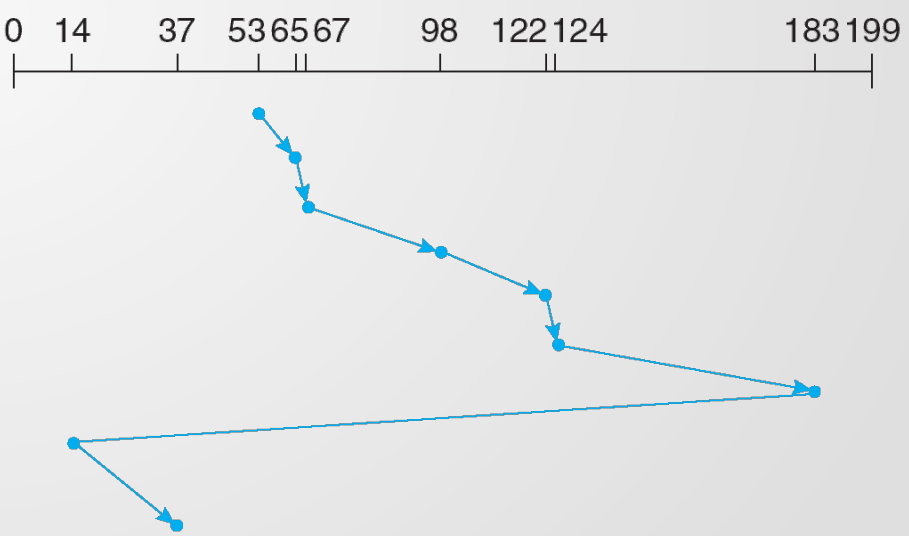

- **Cosa scegliere?**
  - scansione circolare ad alto carico;
  - scansione o SSTF a basso carico.

Sistemi RAID

- Un altro modo per aumentare le **prestazioni** è sfruttare il **parallelismo** anche per l'I/O su disco:
  - servono più **dischi indipendenti**;
  - si suddividono i dati relativi ad una unità logica (un file, in generale un volume) su più dischi: **striping**;
    - suddivisione **trasparente all'utente**;

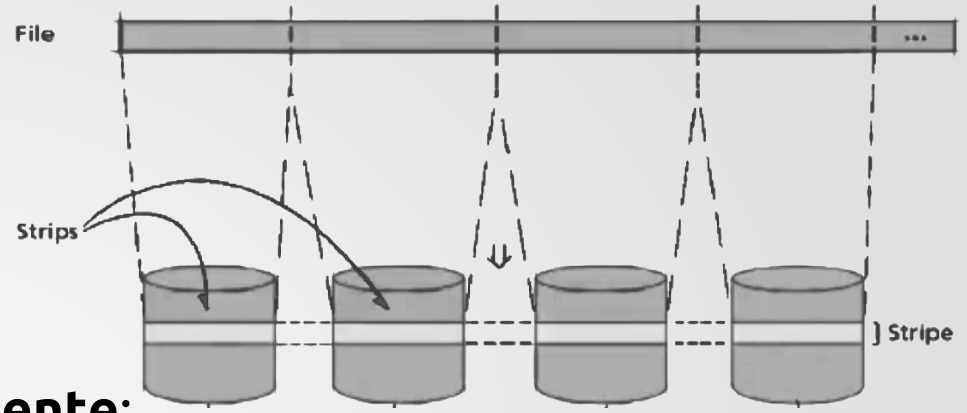

- problema: aumenta la probabilità che si **verifichi un guasto** sul volume logico RAID;
  - soluzione: aggiungiamo ridondanza per ottenere migliore **affidabilità**;
  - sostituzione automatica: dischi **spare**;
- **Redundant Array of Inexpensive Disks** (**RAID**);
  - noti anche come **Redundant Array of Independent Disks**;
- vedremo vari schemi di gestione che bilanciano questi due aspetti;
  - **livelli RAID**;
- via **hardware** (trasparente al S.O.) o via **software** (con carico sulla CPU).

Sistemi RAID

- **RAID 0** (*striping*):
  - fa ***striping*** in modalità round-robin;
  - semplice con **prestazioni ottimali** con letture di grandi volumi;
  - niente ridodanza: **maggiore vulnerabilità**;

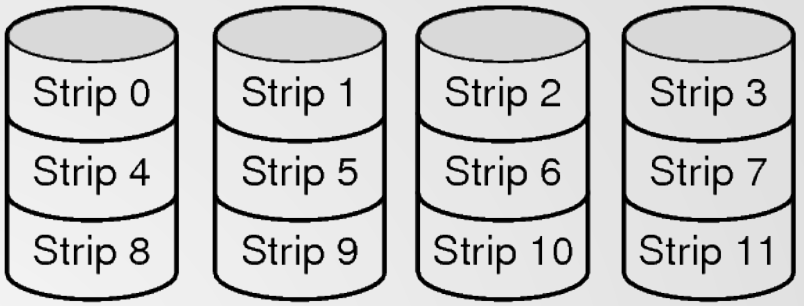

- **RAID 1** (*mirroring*):
  - gli eventuali stripe vengono anche duplicati (***mirroring***);
  - può anche essere usato senza striping;
  - raddoppio prestazioni in lettura;
  - migliore ***fault tollerance***;
  - alto **overhead** di storage;

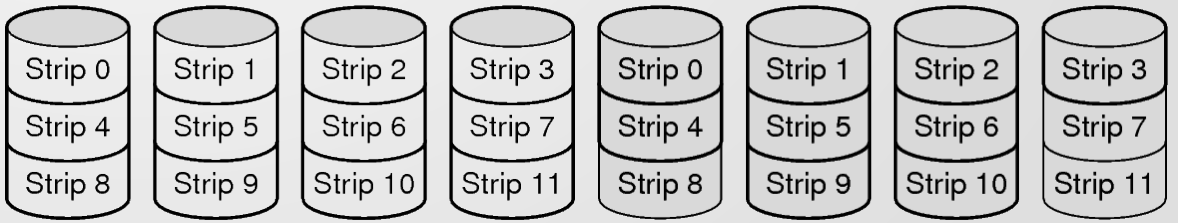

Sistemi RAID

- **RAID 2** (*striping a livello di bit con ECC*):
  - lavora sulle parole applicando un codice di correzione degli errori – ECC (tipo **codice di Hamming** per singoli bit di errore);
  - esempio: 4 bit dati + 3 bit ridondanza;
  - ottima **fault tollerance**;

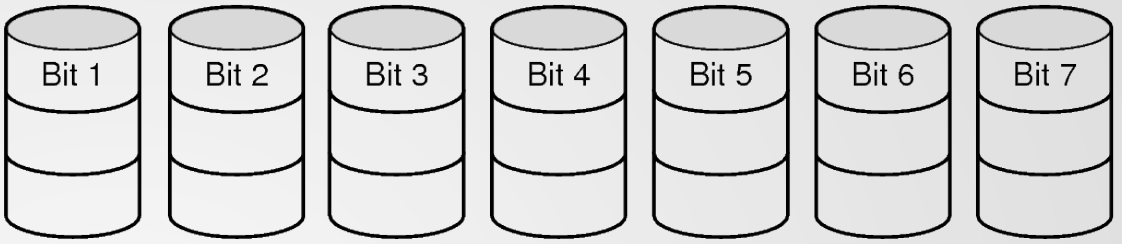

  - serve **sincronia** nelle rotazioni dei dischi;
- **RAID 3** (*striping a livello di bit con bit di parità*):
  - usa un solo disco con raccolti i singoli **bit di parità**;
  - in realtà permette anche di **recuperare** i dati e offre la stessa capacità di fault tollerance del RAID 2;
  - serve ancora sincronia;

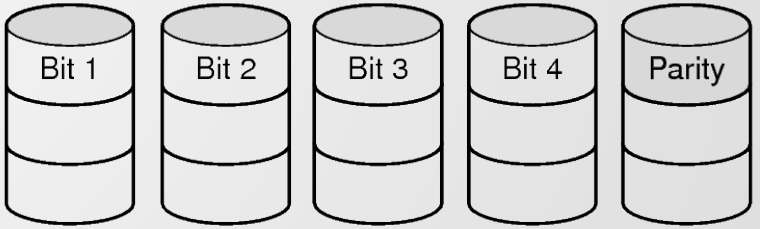

- fare striping a livello di bit è comunque pesante se non gestito a livello hardware;

Sistemi RAID

- **RAID 4** (*striping a livello di blocchi con XOR sull'ultimo disco*):
  - basato sullo **striping a blocchi**;
  - disco extra = **XOR** degli strip;
  - non necessità sincronia;
  - ottima fault tollerance;
  - **aggiornamento** lento in caso di modifica di un blocco?
    - **ottimizzazione**: il nuovo blocco di parità si può calcolare dal blocco sovrascritto e dal vecchio blocco di parità;

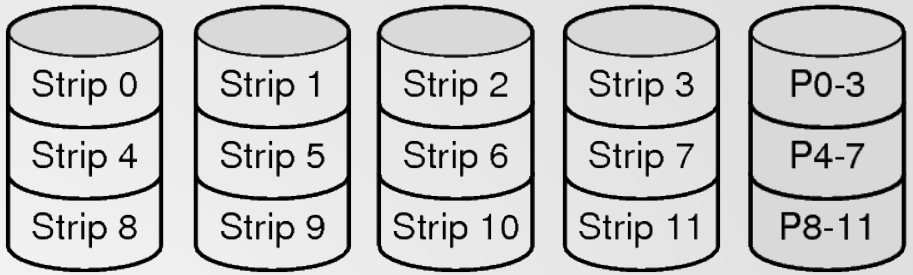

- **RAID 5** (*striping a livello di blocchi ma con informazioni di parità distribuite*):
  - il blocchi di parità del RAID 4 vengono distribuiti su tutti i dischi;
  - di fatti sostituisce il RAID 4.

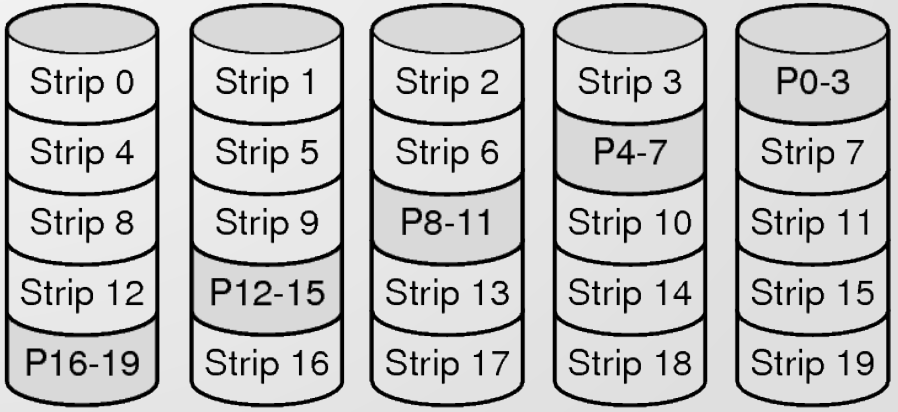

Solid State Disk (SSD)

- I dispositivi basati su memorie flash (**tecnologia NAND**):
  - **letture molto più veloci** delle scritture;
    - un blocco si deve **cancellare prima** di poter essere riscritto;
    - il numero di cancellature è **limitato** per ogni blocco;
  - **blocco** (unità di cancellazione) composto da **pagine** (unità di allocazione);
    - le letture/scritture sono basata su pagine;
- i **file-system** classici basati su principi diversi;
  - file-system ad-hoc: **Flash-Friendly File System** (F2FS), log-based fs, …;
  - controller che rimappano i blocchi tramite un **Flash Translation Layer**;
- **garbage collection** e operazione **TRIM**:
  - **degrado** delle prestazioni nel tempo se non impiegato;
  - richiede **adeguamento** da parte del S.O.